

시각 정보의 청각 변환을 활용한 시각장애인 보행 보조 서비스

기술 조사 보고서: 단안 영상 → 깊이 → 3D → 공간음향

3조 이지호 20201068 · 박상우 20214327 · 박민서 20226292

2026. 09. 24. | 기술 조사 초안 v0.1 (멘토링 과제 T3·T6 대응)

목차

1. 조사 범위와 전체 파이프라인	1
2. 1단계: 영상 → 깊이	2
3. 2단계: 깊이 → 3D	4
4. 3단계: 3D → 공간음향	6
5. 모듈 계약과 안전 처리	7
6. 진행 순서와 비교 실험 계획	8
참고 출처	10

1 조사 범위와 전체 파이프라인

1차 멘토링은 입력 장비와 핵심 기능을 고정하고, 사용 가능한 기술의 **입출력 형태·무게·실행 부담**을 구체적으로 조사할 것을 요구하였다(B1·B5). 본 보고서는 팀이 정한 세 단계, 즉 ① 단안 영상에서 깊이 계산, ② 깊이 맵에서 3D 표현, ③ 3D에서 공간음향에 필요한 기술 후보와 확인할 점을 정리한다. [D2]

세 단계는 흐름상 타당하지만, 실제로 연결하면 단계 사이에 **카메라 내부 파라미터**, **바닥 분리**, **시간적 안정화**, **머리 좌표 변환**이 필요하다. 특히 바닥을 분리하지 않으면 “최근접 표면”은 거의 항상 발밑 바닥이 되어, 프로포절의 대표점 비교가 성립하지 않는다. [D1]




그림 1. 전체 파이프라인. 회색 실선 상자는 처음 정의한 세 단계, 점선 상자는 연결을 위해 추가로 필요한 처리이다. 굵은 테두리는 팀의 설계 기여가 집중되는 대표점 선정 단계이다.

표 1. 단계별 입출력과 이번 조사에서 답할 질문.

단계	입력 → 출력	이번 조사에서 답할 질문
① 영상 → 깊이	RGB 프레임·카메라 파라미터 → 미터 단위 깊이 맵	상대 깊이로 충분한가? 어떤 모델·API가 팀 기기에서 돌아가는가?
② 깊이 → 3D	깊이 맵 → 카메라 좌표 점군 → 장애물·대표점	지도를 누적해야 하는가? 바닥·돌출부를 어떻게 다루는가?
③ 3D → 공간음향	머리 기준 (θ, ϕ, r) → 바이노럴 음향	어떤 엔진을 쓰는가? 방향·거리·높이 중 무엇이 잘 전달되는가?

자료 범위. 외부 자료는 2026.09.24. 웹 검색으로 확인한 공식 저장소·문서·논문 기준이다. 성능 수치는 각 출처의 측정 조건을 따르며, 팀 기기에서 재측정하기 전에는 채택 근거로 쓰지 않는다. [R*]는 외부 출처, [D*]는 팀 문서이다.

2 1단계: 영상 → 깊이

2.1 상대 깊이와 절대 깊이 — 가장 먼저 정할 선택

단안 깊이 추정에는 두 종류로 나뉜다. **상대 깊이**는 물체 사이의 앞뒤 순서를 맞추는 데 초점을 두고, **절대(metric) 깊이**는 카메라와 물체 사이의 거리를 미터 단위로 예측한다. [R9] 멘토가 우려한 스케일 문제(B1)의 본질은 여기에 있다. 단일 영상만으로는 촬영 카메라에 따라 스케일이 모호해져, metric 깊이의 zero-shot 일반화가 특히 어렵다. [R4]




그림 2. 상대 깊이와 절대 깊이. (b)는 순서는 맞지만 “몇 m인가”에 답하지 못한다. 거리에 따라 음량·반복 주기를 바꾸려면 (c)가 필요하다. 값은 설명용 예시이다.

“가까워질수록 음량이 커진다”는 프로포절의 핵심 기능을 구현하려면 미터 단위가 필요하다. 상대 깊이를 쓰려면 바닥까지의 높이나 IMU 이동량 같은 별도 기준으로 스케일을 복원해야 한다. 따라서 첫 프로토타입은 **metric 출력 모델** 또는 **metric API**를 기본값으로 두는 안을 제안한다.

2.2 깊이 후보 비교

표 2. 깊이 취득 후보. 채택 여부는 2.4절과 6절의 실측 후 결정한다.

후보	출력	강점	확인할 점
Depth Anything V2 Metric (S·B·L)	metric 깊이	실내(Hypersim)·실외(Virtual KITTI 2) 용 모델이 크기별로 공개. Small은 24.8M 매개변수로 가장 가벼움 [R1]	실내·실외 모델을 상황에 따라 나눠 써야 함. 크기별 라이선스 확인
Depth Anything 3 Metric-Large	metric 깊이	단안 metric 전용 미세조정 모델. 미터 값 = 초점거리 × 출력 / 300 [R2]	초점거리를 알아야 함. Large급이라 모바일에는 무거움
Video Depth Anything (metric)	영상 metric 깊이	긴 영상에서도 프레임 간 일관성 유지. Small·Base metric 모델과 스트리밍 모드 제공 [R3]	PC 메모리 요구(표 8). 모바일 이식 사례 미확인
UniDepthV2 · Metric3D v2 · Depth Pro · MoGe-2	metric 깊이	대표적인 zero-shot metric 모델군 [R4]	기준선 비교용. 모바일 실행 부담이 큼
ARCore Depth API	metric 깊이 + 자세	모델 없이 RGB 카메라로 깊이 생성, ToF 없이도 지원 [R5]	기기가 움직여야 함. 지원 기기 한정. 얇은 돌출부 성능 미확인

2.3 ARCore Depth API — Android 선택 시의 기준선

ARCore Depth API는 신경망 한 장 추정이 아니라, 기기를 움직이며 얻은 **여러 시점의 영상을 비교하는 depth-from-motion** 방식이다. 정지 상태에서는 머신러닝으로 보완한다. 깊이는 **0.5 m~약 5 m**에서 가장 정확하고, 기기가 움직일수록 결과가 좋아진다. [R5] 이 거리 범위는 보행 중 근거리 장애물 탐지와 겹치며, 보행 자체가 움직임을 제공한다는 점도 유리하다.




그림 3. 단일 영상 추정과 depth-from-motion. (a)는 한 장으로 즉시 추정하지만 스케일과 시간적 일관성이 약점이다. (b)는 움직임이 필요한 대신 미터 단위와 카메라 자세를 함께 얻는다.

확인할 구분. ARCore 호환 기기라도 처리 성능 문제로 Depth API를 지원하지 않는 기기가 있다. [R5] 팀 보유 기기의 지원 여부부터 확인한다. ARCore를 채택해도 팀의 설계 기여(대표점·안내 정책)는 그대로 유지되며, 깊이 소스만 바뀐다.

2.4 실행 부담과 지연 예산

단말 내 추론 가능 여부는 기기 세대에 따라 크게 달라진다. 아래는 Qualcomm AI Hub에 공개된 Depth Anything V2 Small(입력 518×518, FP16, NPU)의 추론 시간이다. [R6]

표 3. Depth Anything V2 Small의 모바일 추론 시간 공개 기록. [R6]

기기 (칩셋)	런타임	추론 시간	비고
Galaxy S23 (Snapdragon 8 Gen 2)	TFLite / ONNX	329 ms / 227 ms	모델 카드 표
Galaxy S24 (Snapdragon 8 Gen 3)	TFLite / ONNX	251 ms / 188 ms	모델 카드 표
Snapdragon 8 Elite QRD	TFLite	236 ms	모델 카드 표
Snapdragon 8 Elite Gen 5 QRD	LiteRT (QNN 위입)	19.8 ms	2026.05 프로파일 기록

해석의 경계. 마지막 행은 측정 시점과 런타임 버전이 달라 위 행들과 직접 비교할 수 없다. 이 표는 “기기와 런타임에 따라 10배 이상 차이가 날 수 있다”는 근거로만 사용하고, 팀 기기에서 재측정한다.

지연은 곧 거리 오차가 된다. 카메라가 본 순간과 소리가 들리는 순간 사이에 사용자는 계속 걷는다. 보행 속도를 약 1.2 m/s로 가정하면 종단간 지연이 거리 오차로 바로 환산된다. 개인별 보행 속도 차이는 크므로 실험에서 따로 기록한다.




그림 4. 종단간 지연과 거리 오차. 안내 거리는 촬영 시점 기준이므로, 사용자는 안내된 거리보다 $\Delta t \times$ 보행 속도만큼 더 가까이 있다.

표 4. 종단간 지연에 따른 이동 거리 (보행 속도 1.2 m/s 가정).

종단간 지연 Δt	100 ms	200 ms	300 ms	500 ms
지연 중 이동 거리	약 12 cm	약 24 cm	약 36 cm	약 60 cm

3 2단계: 깊이 → 3D

3.1 역투영: 깊이 맵을 점군으로

깊이 맵의 각 픽셀은 카메라 중심에서 나가는 광선 위의 한 점에 대응한다. 카메라 내부 파라미터 (초점거리 $f_x \cdot f_y$, 주점 $c_x \cdot c_y$)를 알면 님은꼴 삼각형으로 픽셀 (u, v) 와 깊이 d 에서 3D 좌표를 계산할 수 있다. 모델이나 SLAM 없이 행렬 연산만으로 끝나는 단계이다.




그림 5. 핀홀 카메라 모델과 역투영. 이미지 평면의 픽셀과 카메라 중심을 잇는 광선 위에서, 깊이 d가 주어지면 점 P의 위치가 정해진다. 그림은 옆에서 본 단면(Y-Z)이다.

파라미터 취득. 체커보드 캘리브레이션(OpenCV)으로 직접 구하거나, Android Camera2가 제공하는 렌즈 내부 파라미터 값을 사용한다. 두 값을 비교해 차이를 기록한다. DA3 Metric처럼 초점거리를 요구하는 모델은 이 값이 틀리면 거리 전체가 비례해서 틀린다. [R2]

3.2 프레임 단위 점군과 누적 지도

“3D 맵”은 두 가지 구현 목표를 뜻할 수 있다. 멘토링 정리 보고서 3.2절의 구분과 같다. [D2] (a) **프레임 단위 점군**은 현재 보이는 표면만 다루며 역투영만으로 얻는다. (b) **누적 지도**는 시야에서 벗어난 장애물도 기억하지만, 프레임마다 카메라 자세(pose)가 필요하다.




그림 6. 프레임 단위 점군과 누적 지도(위에서 본 모습). (a)는 시야 밖의 장애물 B를 잊는다. (b)는 기억하지만 자세 T1~T3를 추정해야 한다.

자세 추정을 직접 구현하면 VIO·SLAM 영역이 되어 난도가 급격히 오른다. Android에서는 ARCore 모션 트래킹이 자세를 제공한다. [R5] 시야 밖 장애물을 기억해야 하는 요구가 사용자 조사에서 확인되기 전까지, MVP는 (a)로 한정하는 안을 제안한다.

3.3 점군 후처리와 대표점 선정

역투영 점군을 그대로 쓰면 최근점 점은 발밑 바닥이 된다. 대표점 비교 전에 바닥 분류, 군집화, 이동 범위 필터를 순서대로 적용한다. 네 번째 단계가 프로포절 그림 1의 세 방식 비교에 해당한다. [D1]




그림 7. 점군 후처리 흐름. (1) 원시 점군에서는 바닥이 최근접이 된다. (2) 중력 방향으로 바닥을 분류한다. (3) 몸 폭 통로 안의 군집만 남긴다. (4) 같은 장애물에서 중심점·최근접·범위 내 최근접을 비교한다.

표 5. 후처리 단계별 방법 후보와 실패 시 증상. 도구는 PC 실험 기준(Open3D·numpy)이다.

단계	방법 후보	실패 시 증상과 대응
다운샘플링	복셀 그리드	복셀이 크면 얇은 돌출부가 사라짐 → 크기를 실험 변수로 둠
바닥 분류	IMU 중력 방향 + RANSAC 평면	경사로·계단에서 오분류 → 높이 변화는 제거하지 않고 별도 유형으로 표시
군집화	DBSCAN · 유클리드 군집	붙은 물체가 병합되거나 하나가 쪼개짐 → 거리 임계값 조정
이동 범위 필터	몸 폭·키 높이의 3D 통로	방향 전환 중 통로가 틀어짐 → 휴대폰 방향 대신 진행 방향 추정 검토
대표점·안정화	3방식 + 시간 평활(이동 평균 등)	음원이 팀 / 평활이 강하면 지연 증가 → 흔들림과 지연을 함께 측정

4 3단계: 3D → 공간음향

4.1 카메라 좌표에서 머리 좌표로

공간음향 엔진은 듣는 사람의 머리를 기준으로 한 방향과 거리를 입력으로 받는다. 휴대폰이 가슴에 있고 기울어져 있으면, 카메라 기준 “정면”과 머리 기준 “정면”이 다르다. 프로토타입은 초기 실험에서 휴대폰과 머리의 상대 자세를 고정하기로 하였으므로, 이 변환을 상수로 측정해 두면 된다. [D1]




그림 8. 좌표 변환. (a) 카메라 좌표를 머리 좌표로 옮기는 변환 T. (b) 머리 기준 방위각 θ , 거리 r(고도각 ϕ 포함)가 HRTF 렌더링의 입력이 된다.

4.2 공간음향 엔진 후보

표 6. HRTF 기반 공간음향 엔진 후보.

후보	특징	확인할 점
OpenAL Soft	Linux·Windows·Android·iOS 등 다중 플랫폼, HRTF 출력 지원 [R7]. 음원 위치만 지정하는 단순한 API	기본 HRTF 데이터의 방향 지각, 출력 지연. PC·모바일 공용 엔진으로 1순위 후보
Steam Audio (Valve)	HRTF·가림·반사 지원, SDK 소스 공개, Android·iOS 라이브러리 제공 [R8]	반사·잔향은 이 프로젝트에 과한 기능. 통합 난도 비교
Resonance Audio (Google)	모바일 지향 공간음향 SDK	현재 유지보수 상태 미확인 → 채택 전 확인
iOS AVAudioEnvironmentNode	iOS 기본 HRTF 렌더링	Mac 부재로 현재 개발 제약 (B6)
Android 시스템 Spatializer	멀티채널 콘텐츠 입체화 중심으로 파악	객체별 좌표 제어 적합성 미확인 → 공식 문서 확인

4.3 청각 지각의 한계

HRTF는 방향 정보를 주지만 모든 방향을 같은 정확도로 전달하지는 않는다. 개인 맞춤형이 아닌 일반 HRTF에서는 특히 **앞뒤 혼동**과 **높이 지각 약화**가 알려져 있다. 머리 높이 돌출부를 소리의 높이만으로 전달하려는 설계는 실험으로 확인해야 한다.




그림 9. 방향별 전달 특성. 앞-오른쪽과 뒤-오른쪽 음원은 양귀 도달 시간차가 같아 혼동될 수 있다. 거리는 HRTF가 아닌 팀의 매핑 설계로 전달한다.

표 7. 거리 표현 방식 후보. 한 가지로 고정하지 않고 비교 실험 변수로 둔다.

방식	설계 예	장점	우려
음량	가까울수록 크게	직관적	주변 소음에 약함, 청취 부담
반복 주기	주차 센서처럼 가까울수록 빠르게	거리 변화에 민감	여러 음원이 동시에 올리면 혼잡
음높이	가까울수록 높게	음량과 독립적으로 조절	물체별 음색 구분과 충돌 가능
음성 보조	“1미터 앞”	정확한 수치 전달	발화 지연, 반복 억제 필요

5 모듈 계약과 안전 처리

멘토는 핵심 기능을 모듈화해 개발 의존성을 줄이라고 권고하였다(B4). 네 모듈이 주고받는 데이터를 먼저 고정하면, 각 팀원이 녹화 영상·저장된 깊이 맵·모의 장애물 좌표로 독립 개발할 수 있다. [D2]




그림 10. 모듈 간 데이터 계약안. 상단은 모듈과 프로포절 표 5 기준 담당, 하단은 각 모듈이 다음 모듈로 넘기는 메시지 필드이다. 담당은 재합의 대상이다.

계약에서 가장 중요한 필드는 **t_capture(촬영 시각)**이다. 모든 메시지가 촬영 시각을 전달하면 음향 단계에서 정보가 얼마나 오래되었는지 판단할 수 있다. 허용 지연을 넘은 좌표는 재생하지 않는다. 이는 정리 보고서 표 10의 “정보 만료” 처리를 코드 수준으로 구현하는 방법이다. [D2]

단독 시험 방법 — 제안. 입력 취득은 녹화 재생으로, 깊이 추정은 저장된 프레임으로, 3D·대표점은 저장된 깊이 맵으로, 음향은 미리 정한 (θ , ϕ , r) 목록으로 각각 시험한다.

중단간 시험. 매주 한 번은 녹화 영상에서 음향 출력까지 전체를 연결하고, 단계별 처리 시간과 대표점 좌표를 로그로 남긴다.

안전의 경계. 만료 처리는 “오래된 정보를 새 정보처럼 재생하는 오류”만 막는다. 깊이 모델이 장애물을 놓친 경우 (미검출)는 막지 못하므로, 무음을 “장애물 없음”으로 안내하지 않는 원칙을 유지한다. [D1, D2]

6 진행 순서와 비교 실험 계획

6.1 단계별 진행 — 제안

모바일 이식부터 시작하면 깊이 품질 문제와 플랫폼 문제가 섞여 원인을 구분하기 어렵다. 먼저 PC에서 녹화 영상으로 중단간 동작을 확보하고, 깊이 소스를 비교한 뒤, 팀 기기의 실측 속도를 보고 배치를 결정하는 순서를 제안한다.




그림 11. 진행 순서. 각 단계의 산출물은 멘토링 후속 과제(T3·T7)와 연결된다. 3단계의 세 선택지는 2단계 결과와 기기 실측으로 결정한다.

표 8. 1단계 PC 프로토타입 구성안 (Windows · RTX 4060 · Python).

모듈	도구 후보	비고
프레임 취득	OpenCV (영상 읽기·체커보드 캘리브레이션)	팀 휴대폰으로 녹화한 영상과 그 카메라의 K를 함께 저장
깊이 추정	PyTorch + DA V2 Metric-Indoor-Small, Video Depth Anything Small metric	VDA README 표 기준 Small은 FP16에서 약 6.8 GB 사용 [R3] → 8 GB GPU에서 실측 필요
3D·대표점	numpy 역투영, Open3D (평면 추정·군집·시각화)	그림 7의 네 단계를 함수 단위로 분리
음향	OpenAL Soft + Python 바인딩	바인딩 동작은 설치 후 확인. 대안: Steam Audio
기록	단계별 처리 시각·대표점 좌표 CSV	지연·흔들림 측정의 원자료

6.2 비교 실험 설계

표 9. 같은 녹화 장면으로 수행할 비교 실험. 목표 수치는 정하지 않고 비교 결과를 기록한다.

비교 대상	조건	측정 지표
깊이 소스	DA V2 Metric / VDA metric / ARCore Depth / 줄자 실측	거리 오차, 얇은 돌출부 누락, 프레임 간 흔들림, 처리 시간
대표점 방식	중심점 / 최근점 표면 / 이동 범위 내 최근점	방향 오차, 음원 각도의 흔들림, 돌출부 누락
거리 표현	음량 / 반복 주기 / 음높이 (표 7)	팀원 예비 청취 후 사용자 평가 후보 선정 (수요 근거로 쓰지 않음)
시험 장면	실내 정적 장애물: 의자, 책상 모서리, 기둥, 머리 높이 돌출	장면별 실패 사례를 따로 기록

6.3 확인이 필요한 항목

표 10. 채택 전에 확인할 미확인 사항.

항목	영향을 받는 결정	확인 방법
팀 보유 휴대폰의 기종·칩셋	단말 내 추론 가능 여부	기기 목록 작성, 표 3의 칩셋과 대조한 뒤 실측
ARCore Depth 지원 여부	깊이 소스 후보	공식 지원 기기 목록 확인, 실기기에서 깊이 세션 실행
모델별 라이선스	배포·공개 가능 범위	각 모델 카드·저장소의 라이선스 확인 (크기별 상이 가능)
카메라 내부 파라미터	역투영·DA3 거리 정확도	캘리브레이션 값과 기기 제공 값 비교
Resonance·Android Spatializer 상태	음향 엔진 선택	공식 문서의 지원 상태·API 범위 확인
HRTF 데이터 선택	방향 지각 품질	기본 HRTF로 시작, 다른 공개 HRTF 세트 비교는 후속

다음 멘토링에 가져갈 것 — 제안. (1) 녹화 영상 → 음향까지의 PC 종단간 시연, (2) 깊이 소스 비교표와 실패 사례, (3) 단계별 지연 측정값, (4) 표 10 중 해결되지 않은 항목. 이는 멘토의 “작게 먼저 동작”(A3)과 “기술 조사·설계”(B5)에 대한 직접적인 답이 된다.

참고 출처

- [R1] Depth Anything V2. GitHub (DepthAnything/Depth-Anything-V2) 및 Hugging Face Metric 모델 카드 (Metric-Indoor/Outdoor, Small-Base-Large).
- [R2] ByteDance-Seed. Depth Anything 3. GitHub (ByteDance-Seed/Depth-Anything-3), PyPI depth-anything-3.
- [R3] Video Depth Anything. GitHub 저장소 README (metric 모델·스트리밍 모드·속도·메모리 표).
- [R4] Survey on Monocular Metric Depth Estimation. arXiv:2501.11841. 및 단안 깊이 추정 리뷰 arXiv:2609.01172 (UniDepthV2·Depth Pro·MoGe-2·Metric3D v2 서지).
- [R5] Google. ARCore Depth 개요 및 개발자 가이드. developers.google.com/ar/develop/depth
- [R6] Qualcomm AI Hub. Depth-Anything-V2 모델 카드 (Hugging Face qualcomm/Depth-Anything-V2) 및 프로파일 작업 기록 (2026.05.30).
- [R7] OpenAL Soft. 공식 사이트 openal-soft.org
- [R8] Valve. Steam Audio 공지 (SDK 소스 공개) 및 audionimbus 문서 (플랫폼별 라이브러리 목록).
- [R9] MapAnything: Evaluating Monocular Metric Depth Models for 3D Urban Asset Localization. arXiv:2509.14839 (상대·절대 깊이 정의).
- [D1] 3조. 시각 정보의 청각 변환을 활용한 시각장애인 보행 보조 서비스 — 프로포절 보고서, 4쪽.
- [D2] 3조. 1차 산업체 멘토링 정리 보고서 v1.0, 2026.09.22. (A1~A3, B1~B7, C1~C2, T1~T10)
- [D3] 3조. 시각장애인의 보행 생태계와 보행 보조 서비스 분석 — 요약보고서.

해석의 경계. 본 보고서의 모델 성능·지원 범위는 각 출처의 공개 설명이며 팀이 독립 검증한 결과가 아니다. 파이프라인 구성, 진행 순서, 실험 설계는 팀 합의 전의 제안이다. 버전·라이선스·수치는 채택 시점에 다시 확인한다.